

Universidade Estácio de Sá
Relatório técnico

Análise de Dados do Tempo de entrega do E-Commerces Brasileiro

Antonio Ferreira Moura Junior

Prof. Bruno Martins Bartolomeu

Novembro 2025

Agradecimentos

Agradeço primeiramente a Deus por ter me dado a oportunidade de apresentar e compartilhar meu conhecimento através deste documento, aos meus pais que sempre me incentivaram em todo meu caminho, a minha esposa que tem sido meu maior incentivo.

Artigo Técnico

1. Introdução
2. Metodologia CRISP-DM
3. Implementação
4. Entendimento do Negócio
5. Entendimento dos Dados
6. Preparação dos Dados
7. Modelagem
8. Conclusão
9. Referências Bibliográficas
10. Material Suplementar

RESUMO

O presente Relatório Técnico tem como objetivo principal analisar o tempo de entrega de produtos de e-commerce no Brasil, utilizando um conjunto de dados públicos disponibilizado pela Olist. A análise segue a metodologia CRISP-DM (Cross-Industry Standard Process for Data Mining), abrangendo as fases de Entendimento do Negócio, Entendimento dos Dados, Preparação dos Dados, Modelagem e Avaliação.

O crescimento exponencial do comércio eletrônico torna a eficiência logística, especialmente o tempo de entrega, um fator crítico de satisfação do cliente e competitividade. Este estudo busca identificar padrões, variáveis influentes e possíveis insights para a otimização dos prazos de entrega no contexto brasileiro. Serão exploradas características como a distância entre vendedor e cliente, o peso e volume total do pedido e a região geográfica para construir modelos preditivos que possam estimar o tempo de entrega e auxiliar as empresas a aprimorar suas operações logísticas.

1 Introdução

A grande ascensão do comércio eletrônico (e-commerce) no Brasil, impulsionada significativamente pelos eventos globais recentes, transformou drasticamente o panorama de consumo e varejo. Nesse cenário altamente competitivo, a logística se estabeleceu como um diferencial crucial, e o tempo de entrega se tornou um dos principais fatores de satisfação e retenção de clientes. Prazos longos ou imprevisíveis podem comprometer a experiência do usuário e desviar o consumidor para concorrentes que oferecem maior eficiência no tempo de entrega.

Diante disso, o presente Relatório Técnico propõe uma análise aprofundada sobre a dinâmica do tempo de entrega no e-commerce brasileiro. Utilizando um conjunto de dados públicos robusto, fornecido pela Olist, uma das maiores plataformas de comércio eletrônico do país, o objetivo é aplicar a metodologia Cross-Industry Standard Process for Data Mining (CRISP-DM) para explorar, entender e modelar as variáveis que influenciam a velocidade de entrega. Este estudo visa não apenas descrever o estado atual das entregas, mas também fornecer insights preditivos valiosos, examinando a correlação entre fatores como a distância geográfica (cliente-vendedor), características do produto (peso e volume) e a região de destino. Os resultados esperados contribuirão para otimizar as cadeias de suprimentos, aprimorar a previsão de prazos e, conseqüentemente, elevar o nível de serviço oferecido pelas empresas de e-commerce no Brasil.

2 Metodologia CRISP-DM

Publicado em 1999 para padronizar processos de mineração de dados em diversos setores, essa metodologia se tornou, desde então, a metodologia mais comum para projetos de mineração, análise e ciência de dados.

O CRISP-DM, em tradução livre, significa “processos padrão de Data Mining para qualquer indústria” (cross industry standard processes for Data Mining em inglês), possuindo 6 etapas no total, começando pelo entendimento do negócio onde busca entender objetivos do negócio, avaliar a situação atual, entender os objetivos de modelagem e realizar o planejamento do projeto. É nessa etapa onde o esforço é direcionado não para buscar responder as perguntas, mas sim, realizar as perguntas corretas para atingir o objetivo determinado no início do projeto.

Sua segunda etapa tem como objetivo o entendimento dos dados a serem utilizados, buscando entender sua fonte, sua coleta, descrever, explorar e avaliar a qualidade desses dados.

Na terceira etapa se encontra a preparação dos dados, nesse momento é onde são selecionados os dados a serem utilizados no projeto, feita a limpeza e toda a sua manipulação e integração dos dados entre si e feita sua formatação.


Na quarta etapa temos a modelagem, aqui é determinado a técnica ou as técnicas a serem utilizadas para a modelagem, é construído e avaliado entre os modelos.

Temos a avaliação dos resultados como a quinta etapa, como o nome sugere, são avaliados os resultados dos modelos através de métricas específicas a depender de cada modelo, dados e projetos.

Por fim, a implantação segue como a sexta etapa da metodologia, nesse momento é determinado a forma de se realizar implantação desse projeto para que o cliente possa acessar os resultados, é também parte dessa etapa monitorar, gerar um relatório final e revisar o projeto.

O CRISP-DM não é uma metodologia linear onde se segue um passo a passo, mas sim um ciclo de vida completo para um projeto onde, várias vezes, é necessário voltar e revisar etapas anteriores buscando melhorar o resultado final.

Figura 1 - Ciclo de vida da metodologia CRISP-DM.



3 Implementação

A fase de Implementação seguiu rigorosamente as etapas do CRISP-DM, utilizando o ambiente de programação Python, reconhecido por sua versatilidade e robustez no campo da Ciência de Dados. As bibliotecas selecionadas para o desenvolvimento do projeto foram:

Pandas: Essencial para a manipulação e análise estruturada dos dados, desde a leitura dos arquivos CSV até a realização de transformações complexas na fase de Preparação dos Dados.

NumPy: Utilizada para operações numéricas de alta performance, fundamentais na manipulação de arrays e matrizes, especialmente durante a engenharia de *features* e no processamento dos modelos.

Matplotlib e Seaborn: Empregues na fase de Entendimento e Exploração dos Dados, estas bibliotecas foram cruciais para a visualização gráfica e estatística, permitindo a identificação de padrões, *outliers* e a distribuição das variáveis.

Scikit-learn (Sklearn): Esta biblioteca foi o pilar para a Modelagem e Avaliação, oferecendo ferramentas para pré-processamento (como *scaling* e *encoding*), divisão dos dados (treino e teste), e a implementação de diversos algoritmos de *Machine Learning* e métricas de avaliação, como random forest que também será utilizado.

XGBoost: Escolhido como o principal algoritmo para a Modelagem Preditiva. O XGBoost (*Extreme Gradient Boosting*) é um algoritmo de *boosting* eficiente e de alto desempenho, ideal para problemas de regressão e classificação, demonstrando eficácia na previsão do Tempo de Entrega.

4 Entendimento do Negócio

A fase de Entendimento do Negócio, primeira etapa da metodologia CRISP-DM, é crucial para alinhar os objetivos do projeto de Ciência de Dados com as metas estratégicas do setor de e-commerce.

O objetivo principal de negócio é otimizar a experiência do cliente e aumentar a competitividade no mercado brasileiro de comércio eletrônico, focando diretamente na eficiência logística. A insatisfação gerada por prazos de entrega longos ou imprevisíveis é um fator de churn (abandono) significativo.




Figura 2 - Gráfico representando o percentual de pedidos atrasados em relação a nota de avaliação média dos clientes.

Objetivo Central: Prever com precisão o tempo de entrega de pedidos para melhorar a experiência do cliente.

Problema de Negócio: Atrasos na entrega de pedidos geram insatisfação e, consequentemente, baixas avaliações e perda de clientes (churn). A falta de uma estimativa confiável de prazo impede uma gestão de expectativa eficaz.

Portanto, o projeto visa responder à seguinte questão de negócio:

Quais variáveis são mais influentes no tempo de entrega de produtos de e-commerce no Brasil e como podemos utilizá-las para criar um modelo preditivo robusto para estimar o prazo de entrega com maior precisão?

O sucesso deste projeto será medido pela capacidade de fornecer insights acionáveis para:

Redução da Discrepância: Minimizar a diferença entre o prazo de entrega prometido e o prazo de entrega real.

Otimização de Roteamento: Identificar gargalos logísticos regionais e operacionais.

Melhoria da Experiência do Cliente: Promover a satisfação do cliente através de estimativas de entrega mais confiáveis.

Para alcançar o objetivo de negócio, são definidos os objetivos como:

Exploração de Dados: Identificar e quantificar a relação entre variáveis logísticas (distância, peso, volume) e o Tempo de Entrega (variável target).

Modelagem Preditiva: Desenvolver um modelo de regressão (utilizando algoritmos como Random Forest e XGBoost) capaz de prever o tempo de entrega em dias.

Avaliação: Obter um modelo com alta acurácia preditiva.

Critério de Sucesso do Projeto: O modelo final deve reduzir o Erro Quadrático Médio da Raiz (Root Mean Square Error - RMSE) de previsão em comparação com uma estimativa baseline (modelo ingênuo), provando sua eficácia preditiva.

5 Entendimento dos dados

O desenvolvimento do modelo baseou-se no conjunto de dados histórico da OLIST, muito conhecido no meio por ser robusto e conter uma grande quantidade de dados de produtos, vendedores, clientes, etc. se tornando ideal para o estudo atual do projeto. A base é compreendida no período de 2016 a 2018, totalizando 110189 registros de pedidos.

É importante citar que todos os dados sensíveis foram tratados e garantidos que não possa ser vinculado a nenhum cliente ou vendedor que tenha utilizado a plataforma da OLIST nos períodos analisados por esse projeto seguindo a LGPD (lei geral de proteção de dados).

Definição das Variáveis:

A variável alvo (target) do estudo foi definida como o tempo decorrido em dias entre a aprovação do pagamento e a entrega efetiva ao cliente. Para a construção do modelo preditivo, foram selecionadas variáveis explicativas (features) que capturam aspectos logísticos e geográficos fundamentais.

Engenharia de Atributos, (Feature Engineering)

Para enriquecer a capacidade preditiva do modelo, foram derivadas novas variáveis a partir dos dados brutos. Destaca-se o cálculo da distância espacial entre as coordenadas de origem (vendedor) e destino (cliente), visto que a distância é um fator determinante na logística de transporte.

A Tabela 1 resume os atributos utilizados:

Tabela 1: Dicionário de Variáveis do Modelo

Variável	Tipo	Descrição
price	Numérica	Preço total da compra do pedido em Reais
freight_value	Numérica	Preço total do frete do pedido em Reais
product_weight_g	Numérica	Peso total do pedido em gramas
product_total_volume_c3	Numérica	Volume total do pedido em cm ³
dintancia_km	Numérica	Distância entre o cliente e vendedor em quilômetros
purchase_year	Numérica	Ano da confirmação da compra do pedido
purchase_month	Categórica	Mês da confirmação da compra do pedido
purchase_weekday	Categórica	Dia da semana da confirmação da compra do pedido
same_state	Booleana	Verdadeiro se o cliente e vendedor forem do mesmo estado, Falso caso contrário
freight_ratio	Numérica	Relação entre o valor do frete e valor do pedido (Valor Frete / (Valor do Pedido + 0,01))
route_avg_time	Numérica	Tempo médio de entrega entre o estado do cliente e o estado do vendedor
tempo_entrega_dias	Numérica (Alvo)	Tempo em dias para a entrega do pedido ser realizada (Variável Alvo)

6 Preparação dos Dados

A preparação e tratamento dos dados foi conduzido mediante a duas estratégias distintas, adequadas à natureza de cada grupo de variáveis: filtragem espacial determinística e remoção estatística de outliers.

Consistência Geoespacial: Para as variáveis de coordenadas geográficas (latitude e longitude), aplicou-se um filtro de domínio baseado nos limites territoriais do Brasil. Foram considerados válidos apenas os registros situados no intervalo de latitude $[-34.0, 6.0]$ e longitude

$[-74.0, -35.0]$. Esse procedimento eliminou ruídos de georreferenciamento e garantiu que o cálculo subsequente de distâncias operasse exclusivamente dentro da área de interesse logístico.

O cálculo da distância entre os pontos de origem e destino foi realizado através da fórmula de Haversine (Sinnott, 1984), que considera a curvatura da Terra, sendo essencial para a precisão em rotas logísticas.

Tratamento de Variáveis Quantitativas: Para as demais variáveis numéricas contínuas do conjunto de dados, optou-se pela remoção de outliers através do método de truncamento por percentis (winsorização ou corte). Estabeleceram-se como limites de corte o 5º percentil (P 0.05) e o 95º percentil (P 0.95). Registros com valores inferiores a P 0.05 ou superiores a P 0.95 foram excluídos. Essa abordagem permitiu reduzir a variabilidade extrema e a assimetria das distribuições, mitigando o impacto de anomalias que poderiam enviesar os algoritmos de aprendizado de máquina, preservando, contudo, a representatividade central dos dados.

É possível observar nas figuras 3 e 4 dois exemplos mostrando as diferenças dos dados antes e depois do tratamento dos dados.




Figura 3 - Comparação entre o tratamento de outliers gerado no matplotlib, o mapa da direita mostra os dados já tratados.




Figura 4 - Comparação entre a distribuição do volume total do produto em cm^3 onde a primeira imagem mostra possíveis outliers com volumes ultrapassando 250000 cm^3 , na segunda imagem temos os dados tratados.

7 Modelagem e Avaliação de Desempenho

Para estimar o tempo de entrega com precisão, adotou-se uma abordagem experimental baseada no enriquecimento progressivo das features (variáveis). O objetivo foi não apenas encontrar o algoritmo com menor erro, mas também quantificar o ganho de informação trazido por cada grupo de variáveis (datas, logística e rotas).

Foram treinados e avaliados dois algoritmos de aprendizado de máquina baseados em árvores de decisão: Random Forest e XGBoost. A avaliação foi conduzida em quatro cenários distintos de dados, permitindo isolar a contribuição de cada conjunto de atributos:

Cenário 1 (Baseline): Contém apenas os dados brutos iniciais para estabelecer uma linha de base de desempenho.

Cenário 2 (+ Datas): Incorporação de variáveis temporais derivadas (sazonalidade, dias da semana, mês).

Cenário 3 (+ Logística): Adição de informações operacionais como o booleano do mesmo estado e relação do frete com valor.

Cenário 4 (+ Rotas): Inclusão de dados do tempo médio de entrega com base no estado do vendedor e cliente.

Métricas de Avaliação:

O desempenho dos modelos foi mensurado utilizando duas métricas de erro padrão para problemas de regressão:

MAE (Erro Absoluto Médio): Para avaliar a magnitude média do erro em dias.

RMSE (Raiz do Erro Quadrático Médio): Para penalizar erros maiores de forma mais severa, o que é crítico em logística para evitar grandes atrasos inesperados.

Os resultados demonstraram uma redução consistente do erro à medida que a complexidade dos dados aumentou. O Random Forest apresentou desempenho superior ao XGBoost em todos os cenários avaliados, demonstrando maior robustez para este conjunto de dados específico.

A introdução das variáveis de Rota (Cenário 4) provou ser o fator determinante para a maximização da performance preditiva. O melhor modelo obtido foi o Random Forest no Cenário 4, alcançando um RMSE de 6.75 e o menor MAE comparativo. Isso valida a hipótese de que as variáveis geoespaciais e de distância são os preditores mais fortes para o tempo de entrega, superando isoladamente as variáveis temporais ou puramente logísticas.




Figura 5 - Comparação entre os modelos utilizados e cenários, quanto menor, melhor o desempenho do modelo.

Modelo	Cenário	MAE	RMSE
Random Forest	Baseline	4.865512	7.344185
XGBoost	Baseline	4.923160	7.435807
Random Forest	Datas	4.507405	6.911201
XGBoost	Datas	4.640409	7.158513
Random Forest	Logística	4.477978	6.898782
XGBoost	Logística	4.557357	7.004841
Random Forest	Rota	4.337500	6.752988
XGBoost	Rota	4.481675	6.907052

Tabela 2 - Comparativo dos resultados obtidos

8 Conclusão

O estudo demonstrou a eficácia de algoritmos de aprendizado de máquina na previsão de prazos de entrega (Estimated Time of Arrival - ETA), superando estimativas estáticas tradicionais. A análise comparativa evidenciou o Random Forest como o modelo mais robusto para este domínio de dados, alcançando o melhor desempenho (RMSE de 6.75 dias) no cenário que incorporou variáveis de rota e geolocalização.

A superioridade do Random Forest sobre o XGBoost neste experimento sugere que, para a volumetria e as características ruidosas dos dados de logística do dataset Olist, a estrutura de bagging (agregação de árvores independentes) do Random Forest ofereceu melhor generalização e resistência ao overfitting do que a abordagem de boosting do XGBoost.

Crucialmente, a análise incremental de variáveis confirmou a hipótese de que a componente geoespacial é o fator mais determinante para a predição. Enquanto variáveis temporais e logísticas básicas trouxeram ganhos marginais, a inclusão de dados do tempo médio de entrega com base no estado do vendedor e cliente (Cenário "Rotas") foi responsável pelo salto qualitativo na precisão do modelo. Isso indica que a variabilidade do tempo de entrega é explicada majoritariamente pela física do deslocamento e pela capilaridade da malha logística brasileira.

O código completo deste artigo estão no meu repositório do GitHub: [\[https://github.com/0ace-jk/previsao_de_tempo_de_entrega/blob/main/app.ipynb\]](https://github.com/0ace-jk/previsao_de_tempo_de_entrega/blob/main/app.ipynb)

9 Referências Bibliográficas

SCIKIT-LEARN. User Guide. Scikit-learn Developers, 2023. Disponível em scikit-learn.org/stable/user_guide.html

SCIKIT-LEARN. Stochastic Gradient Descent. Scikit-learn Developers, 2023. Disponível em: <https://scikit-learn.org/stable/modules/sgd.html>.

BROWNLEE, Jason. XGBoost With Python: Mini-Course. Machine Learning Mastery, 2016. Disponível em: <https://machinelearningmastery.com/xgboost-with-python/>.

OLIST. Brazilian E-Commerce Public Dataset by Olist. Kaggle, 2018. Disponível em: <https://www.kaggle.com/olistbr/brazilian-ecommerce>.

10 Material Suplementar




Figura 6 - Distribuição da distância em KM antes do tratamento.




Figura 7 - Distribuição do valor do frete antes do tratamento




Figura 8 - Distribuição do preço do pedido antes do tratamento




Figura 9 - Distribuição do volume total do pedido antes do tratamento




Figura 10 - Distribuição do peso do pedido antes do tratamento




Figura 11 - Distribuição da distância depois do tratamento




Figura 12 - Distribuição do preço do frete depois do tratamento




Figura 13 - Distribuição do preço depois do tratamento




Figura 14 - Distribuição do volume do pedido depois do tratamento




Figura 15 - Distribuição do peso do produto depois do tratamento